



ویکی پروژه پایانی درس داده کاوی

دانشکده علوم کامپیوتر دانشگاه تهران

استاد درس: دکتر نادی

نسخه دوم - تاریخ نسخه: ۱۱ خرداد ۱۴۰۵

بهار ۱۴۰۵

۱. معرفی کلی پروژه

در این پروژه، هر گروه روی یک مجموعه داده مشخص کار خواهد کرد و تلاش می‌کند یک چرخه کامل از فرایند داده‌کاوی و یادگیری ماشین را روی آن پیاده‌سازی کند. هدف اصلی این پروژه فقط رسیدن به یک عدد دقت بالا نیست؛ بلکه انتظار می‌رود دانشجویان بتوانند مسئله را درست تعریف کنند، داده را بررسی و آماده‌سازی کنند، روش مناسب انتخاب کنند، نتایج را تحلیل کنند و در نهایت کار خود را در قالب یک گزارش علمی و منظم ارائه دهند.

همچنین انتظار می‌رود هر گروه چند روش مختلف را به صورت مقایسه‌ای بررسی کند و با انجام استخراج ویژگی، تنها از تعداد محدودی از ویژگی‌های مناسب برای مدل‌سازی نهایی استفاده کند.

این پروژه فرصتی است تا مهارت‌هایی که در طول درس آموخته‌اید، از جمله تحلیل داده، پیش‌پردازش، مدل‌سازی، ارزیابی و همچنین مهارت گزارش‌نویسی علمی، در یک مسئله واقعی به کار گرفته شوند.

۲. ساختار کلی پروژه

پروژه در سه فاز انجام می‌شود:

فاز ۱: تشکیل گروه - ۱۵ اردیبهشت

فاز ۲: گزارش پیشرفت - ۲۹ خرداد

فاز ۳: تحویل گزارش نهایی / کد پروژه + ارائه - تاریخ متعاقباً اعلام خواهد شد.

هدف از فاز میانی این است که دانشجویان پروژه را به صورت تدریجی پیش ببرند و انجام کار به روزهای پایانی ترم موکول نشود.

۱.۲. فاز ۱: تشکیل گروه

در این فاز، دانشجویان باید گروه‌های دو نفره تشکیل دهند و اطلاعات اعضای گروه را گروه «بله» درس اعلام کنند. که انتظار می‌رود قبل از انتشار این ویکی و تا روز ۱۵ اردیبهشت انجام شده باشد.

۲.۲. فاز ۲: گزارش پیشرفت اول

- مهلت تحویل: ۲۹ خرداد ۱۴۰۵

در این فاز، هر گروه باید یک گزارش کوتاه از کارهایی که تا این مرحله انجام داده است ارائه کند. این گزارش می‌تواند حدود ۱ تا ۴ صفحه باشد و با ساختار دلخواه و بدون نیاز به ساختار رسمی و کامل گزارش نهایی تحویل داده شود.

محتوای پیشنهادی فاز ۲:

در این گزارش می‌توانید به موارد زیر اشاره کنید:

- معرفی اولیه مجموعه داده
- توضیح کلی مسئله‌ای که می‌خواهید حل کنید.
- بررسی اولیه داده‌ها
- چند نمونه از تحلیل اکتشافی داده‌ها یا **EDA** (برای مثال visualization داده‌هایتان در اینجا بسیار مفید خواهد بود)
- نمودارها یا مشاهدات اولیه
- کارهای انجام‌شده در زمینه پاک‌سازی و پیش‌پردازش داده
- مدل‌های انتخاب‌شده
- دلیل انتخاب مدل‌ها
- معرفی حداقل سه روش یا مدل مختلفی که برای حل مسئله در نظر گرفته‌اید.
- توضیح اولیه درباره اینکه چرا این سه روش برای داده و مسئله شما مناسب هستند.
- در صورت وجود نتایج اولیه، مقایسه مقدماتی این روش‌ها بر اساس معیارهای ارزیابی مناسب.
- نتایج اولیه، در صورت وجود
- معیارها و سنج‌های ارزیابی موردنظر
- مشکلات یا ابهاماتی که تا این مرحله با آن مواجه شده‌اید
- برنامه کلی برای ادامه پروژه

۳.۲. فاز ۳: گزارش نهایی و کد پروژه

در فاز نهایی، هر گروه باید یک فایل فشرده‌شده، شامل گزارش نهایی و کد پروژه، ارسال کند. مهلت دقیق تحویل فاز نهایی متعاقباً اعلام خواهد شد.

فایل نهایی ارسالی باید شامل موارد زیر باشد:

۱. گزارش نهایی پروژه

- می‌تواند در فرمت یک فایل word یا LaTeX ارائه شود.

۲. کدهای پروژه

- در صورت استفاده از فایل Notebook، خروجی‌ها باید داخل Notebook قابل مشاهده باشند.
 - در صورت استفاده از فایل‌های py، خروجی‌های مهم باید در یک فایل متنی جداگانه ارائه شوند.
- فقط یکی از اعضای گروه فایل نهایی را از طرف کل گروه ارسال می‌کند.

۳. مجموعه داده و تعریف مسئله

دیتاست‌ها در لینک زیر قرار داده شده‌اند. هر دیتاست با یک شماره مشخص شده است و هر گروه باید بر اساس شماره گروه خود، دیتاست مربوطه را دریافت کند. شماره هر گروه در انتهای این فایل مشخص شده است.

<https://my.files.ir/drive/s/wI36NR42Jaf7TpKgYRrLxiYcpnRGOO>

دیتاست هر گروه متفاوت است و در جلسه ارائه، یک دیتاست تست مرتبط با همان دیتاست به گروه داده خواهد شد. در نتیجه، در صورتی که از دیتاست اشتباه استفاده کنید، کد شما در روز ارائه اجرا نخواهد شد و نمره‌ای نیز به آن تعلق نخواهد گرفت. بنابراین، **لطفاً هر گروه با دقت و بر اساس شماره تعیین شده در انتهای این توضیح پروژه، دیتاست صحیح خود را انتخاب کند.**

دیتاست هر گروه شامل ۳۴ ویژگی (Feature) است و تسک مورد نظر، طبقه‌بندی (Classification) می‌باشد. همچنین ویژگی هدف با نام «y» مشخص شده است.

استفاده از داده‌های خارجی مجاز نیست. پروژه باید بر اساس همان مجموعه داده‌ای انجام شود که به گروه اختصاص داده شده است.

برای ایجاد امکان مقایسه منصفانه‌تر و همچنین الزام همه گروه‌ها به انجام انتخاب ویژگی، **هر گروه مجاز است حداکثر از ۲۵ ویژگی از میان ویژگی‌های موجود در مجموعه داده استفاده کند.** برای این کار، گروه باید با استفاده از روش‌های مناسب Feature Selection یا تحلیل‌های منطقی، ویژگی‌های مورد استفاده خود را انتخاب کند و دلیل انتخاب یا حذف ویژگی‌ها را در گزارش توضیح دهد.

اگر مجموعه داده بسیار بزرگ بود و اجرای کامل آن با امکانات محاسباتی دانشجویان ممکن نبود، گروه می‌تواند از یک زیرمجموعه مناسب و کافی از داده استفاده کند. در این صورت، باید در گزارش توضیح دهد که چرا از نمونه‌گیری استفاده شده و زیرمجموعه انتخاب شده چگونه نماینده مناسبی از داده اصلی است. **علت آن باید به اندازه کافی مناسب باشد تا مورد تایید باشد (در کل در گزارش نهایی باید علت تمامی تصمیم‌هایتان را توضیح و بررسی کنید).**

۴. مراحل مورد انتظار در پروژه

انتظار می‌رود هر گروه، متناسب با نوع داده و مسئله خود، یک روند کامل داده‌کاوی و یادگیری ماشین را طی کند. مراحل زیر از بخش‌های اصلی پروژه هستند:

۱.۴. شناخت داده

در این بخش باید مجموعه داده **در حد ممکن** بررسی و معرفی شود. برای مثال:

- داده شامل چه ستون‌ها یا ویژگی‌هایی است؟
- هر نمونه در داده نشان‌دهنده چیست؟
- هدف پروژه بر اساس این داده چیست؟
- متغیر هدف، در صورت وجود، کدام است؟
- نوع مسئله چیست؟

۲.۴. تحلیل اکتشافی داده‌ها یا EDA

در این بخش باید داده را از نظر آماری و بصری بررسی کنید. برای مثال:

- بررسی تعداد نمونه‌ها و ویژگی‌ها
 - بررسی نوع ویژگی‌ها
 - بررسی توزیع متغیرهای مهم
 - بررسی ارتباط بین ویژگی‌ها
 - بررسی داده‌های پرت، مقادیر گم‌شده یا الگوهای قابل توجه
 - استفاده از نمودارهای visualization مناسب برای فهم بهتر داده
- نمودارها باید خوانا، دارای عنوان و در صورت نیاز دارای توضیح مناسب باشند. صرفاً قرار دادن نمودار کافی نیست. باید توضیح دهید از هر نمودار چه نتیجه‌ای گرفته‌اید.

۳.۴. پاک‌سازی و پیش‌پردازش داده

بسته به وضعیت مجموعه داده، ممکن است لازم باشد کارهایی مانند موارد زیر انجام دهید:

- مدیریت مقادیر گمشده
- حذف یا بررسی داده‌های تکراری
- بررسی داده‌های پرت
- تبدیل داده‌های متنی یا categorical به فرم عددی
- نرمال‌سازی یا استانداردسازی ویژگی‌ها
- تقسیم داده به بخش‌های آموزشی و آزمایشی
- آماده‌سازی داده برای ورود به مدل

هر تصمیمی که در این مرحله می‌گیرید باید در گزارش توضیح داده شود. برای مثال، اگر ستونی را حذف می‌کنید، باید دلیل آن مشخص باشد یا اگر نرمال‌سازی نکردید باید توضیح دهید چرا.

۴.۴. استخراج ویژگی

در این پروژه، انجام Feature Selection برای همه گروه‌ها الزامی است. هر گروه باید ویژگی‌های مناسب را از میان ویژگی‌های موجود انتخاب کند و مجاز است حداکثر از ۲۵ ویژگی در مدل‌سازی نهایی خود استفاده کند. گروه باید در گزارش توضیح دهد که چه ویژگی‌هایی انتخاب شده‌اند، چه ویژگی‌هایی حذف شده‌اند، و دلیل این تصمیم‌ها چه بوده است.

برای مثال:

- انتخاب ویژگی‌های مهم‌تر
- کاهش ابعاد داده
- آماده‌سازی ویژگی‌ها برای مدل

۵.۴. انتخاب و آموزش مدل

هر گروه موظف است حداقل سه روش یا مدل متفاوت را برای حل مسئله خود بررسی و پیاده‌سازی کند. این روش‌ها باید با استفاده از معیارهای ارزیابی مناسب با یکدیگر مقایسه شوند. در نهایت، گروه باید یکی از این روش‌ها

را به عنوان روش نهایی انتخاب کند و در گزارش توضیح دهد که چرا این روش نسبت به دو روش دیگر مناسب تر بوده است. انتخاب روش نهایی نباید صرفاً بر اساس یک عدد مانند دقت انجام شود؛ بلکه باید عواملی مانند نوع مسئله، کیفیت نتایج، پیچیدگی مدل، تفسیرپذیری، زمان اجرا و تناسب روش با داده نیز در نظر گرفته شود.

استفاده از مدل هایی که در درس معرفی شده اند توصیه می شود، اما محدودیت قطعی به همان مدل ها وجود ندارد. با صرف نظر از اینکه مدل هایی که استفاده می کنید در درس به طور مستقیم تدریس شده یا نشده اند، باید آن ها را در بخش روش های گزارش نهایی تان به خوبی توضیح دهید.

۶.۴. ارزیابی مدل

مدل باید با معیارهای مناسب ارزیابی شود. در مسائل classification می توان از معیارهایی مانند موارد زیر استفاده کرد:

- Accuracy
- Precision
- Recall
- F1-score
- Confusion Matrix

مهم است که فقط عددها را گزارش نکنید، بلکه توضیح دهید این عددها چه معنایی دارند و درباره عملکرد مدل چه چیزی نشان می دهند.

۵. ساختار گزارش نهایی

گزارش نهایی می تواند به زبان فارسی یا انگلیسی نوشته شود. در گزارش فارسی، استفاده از اصطلاحات تخصصی انگلیسی مانند Machine Learning، EDA، Preprocessing، Feature Extraction و Model Evaluation مجاز است.

گزارش باید کامل و کافی باشد و نباید بسیار کوتاه یا سطحی نوشته شود. قالب خاصی مانند Word یا LaTeX اجباری نیست، اما گزارش نهایی باید منظم، خوانا و علمی باشد.

ساختار گزارش

ساختار گزارش باید از بخش بندی زیر (شامل ۷ بخش اجباری و ۲ بخش اختیاری) تبعیت کند و تنها در این فرمت و ساختار پذیرفته خواهد شد:

۱.۵. صفحه عنوان

صفحه عنوان باید شامل موارد زیر باشد:

- عنوان پروژه
- نام درس
- نام و نام خانوادگی اعضای گروه
- شماره دانشجویی اعضای گروه

۲.۵. چکیده

در چکیده، خلاصه‌ای کوتاه از مسئله، داده، روش استفاده‌شده و مهم‌ترین نتایج ارائه می‌شود. برای درک نحوه نگارش چکیده و سایر بخش‌ها می‌توانید به مقاله‌های علمی کنفرانس‌های معتبر یادگیری ماشین مانند NeurIPS و ICLR یا به فهرست پروژه‌های کارشناسی دانشکده مراجعه فرمایید.

۳.۵. مقدمه

در مقدمه باید توضیح دهید که هدف و کاربرد اصلی پروژه چیست و خلاصه‌ای از کارهای پروژه را ارائه دهید. خواننده بعد از خواندن مقدمه باید به ادامه خواندن گزارش شما رغبت کافی پیدا کند.

۴.۵. کارهای مرتبط یا مرور بر کارهای پیشین (اختیاری)

این بخش اختیاری است. اگر گروهی علاقه‌مند باشد، می‌تواند منابع مرتبط، مقاله‌ها، گزارش‌ها یا کارهای مشابه را بررسی و خلاصه کند.

اگر از منابعی در این بخش استفاده می‌کنید، باید به آن‌ها ارجاع دهید و در آخر گزارش کتاب‌نامه‌ای مناسب داشته باشید.

۵.۵. روش‌شناسی

این بخش یکی از مهم‌ترین بخش‌های گزارش است. در این قسمت باید روش خود را توضیح دهید، از جمله:

- نحوه بررسی و آماده‌سازی داده
- مراحل پاک‌سازی و پیش‌پردازش

- توضیح دقیق روش انتخاب ویژگی‌ها و معیار شما برای حذف سایر ویژگی‌ها جهت رسیدن به سقف مجاز.
- معرفی حداقل سه روش یا مدل بررسی شده
- توضیح نحوه آموزش و تنظیم هر یک از روش‌ها
- مقایسه روش‌ها و دلیل انتخاب روش نهایی
- تنظیمات مهم مدل‌ها
- نحوه تقسیم داده برای آموزش و ارزیابی

گزارش باید به گونه‌ای نوشته شود که خواننده بتواند روند کار شما را بفهمد، حتی اگر کد پروژه را باز نکرده باشد.

۶.۵. نتایج و تحلیل

در این بخش باید نتایج مدل‌ها و تحلیل خود را ارائه کنید. این بخش فقط محل قرار دادن جدول و نمودار نیست. بلکه باید توضیح دهید که نتایج چه معنایی دارند.

موارد پیشنهادی برای این بخش:

- ارائه جدول‌های تمیز و خوانا
- ارائه نمودارهای مناسب
- توضیح معیارهای ارزیابی
- مقایسه جامع عملکرد حداقل ۳ مدل پیاده‌شده با مجموعه ویژگی‌های انتخاب شده
- تحلیل اثر Feature Selection بر نتایج، در صورت امکان
- تحلیل عملکرد مدل
- بررسی نقاط قوت و ضعف روش
- توضیح اینکه مدل در چه بخش‌هایی خوب عمل کرده و در چه بخش‌هایی ضعیف‌تر بوده است
- آوردن نمونه از داده‌هایی که مدل در آن عملکرد مناسب و غیرمناسب داشته است

۷.۵. نتیجه‌گیری

در نتیجه‌گیری باید خلاصه‌ای از کار انجام‌شده، مهم‌ترین یافته‌ها و برداشت نهایی خود را بیان کنید.

۸.۵. پیشنهاد برای کار آینده (اختیاری)

در نهایت گزارش‌تان به صورت اختیاری می‌توانید به محدودیت‌های کار و پیشنهادهایی برای بهبود آینده اشاره کنید.

۹.۵. شرح مشارکت اعضای گروه

در انتهای گزارش باید بخشی با عنوان **شرح مشارکت اعضای گروه** اضافه شود.

در این بخش باید به صورت دقیق و شفاف توضیح دهید هر عضو گروه چه کارهایی انجام داده است. این توضیح باید به اندازه کافی جزئی باشد تا مشخص شود هر دانشجو در چه بخش‌هایی از پروژه مشارکت داشته است.

برای مثال:

- عضو اول: بررسی داده، انجام EDA، تولید نمودارها، نوشتن بخش مقدمه، **پیاده‌سازی یک مدل**
- عضو دوم: پیش‌پردازش داده، **پیاده‌سازی مدل دو مدل**، تحلیل نتایج، نوشتن بخش روش و نتایج

این بخش باید واقع‌بینانه نوشته شود.

۶. ارائه پروژه

پس از تحویل پروژه‌ها، برای گروه‌ها جلسه ارائه برگزار خواهد شد. جزئیات دقیق مربوط به زمان ارائه متعاقباً اعلام خواهد شد و برای ارائه نیازی برای تهیه اسلاید ارائه نیست و گزارش به همراه کد کافی است.

در ارائه، انتظار می‌رود اعضای گروه بتوانند کار خود را توضیح دهند و به پرسش‌های مربوط به داده، روش، کد، مدل، ارزیابی و نتایج پاسخ دهند. همچنین در روز تحویل پروژه، باید کد و تمامی مراحل آن **بر روی مجموعه داده تستی که مخصوص شما آماده شده است، اجرا شود**. تمهیدات لازم برای این منظور انجام شود. در صورت عدم اجرا نمره‌ای داده نخواهد شد.

هر دو عضو گروه باید با کلیت پروژه آشنا باشند، حتی اگر تقسیم کار بین اعضا انجام شده باشد. اگر در جلسه ارائه مشخص شود که اعضای گروه با روش‌ها، کد یا نتایج پروژه آشنایی کافی ندارند، این موضوع در ارزیابی پروژه اثرگذار خواهد بود.

با توجه به اینکه پروژه ۱۰ نمره از ۲۰ نمره نهایی درس را به خود اختصاص می‌دهد، ارزیابی و تحویل پروژه‌ها با دقت انجام خواهد شد. هدف از این تاکید ایجاد نگرانی نیست، بلکه شفاف‌سازی انتظارات از ابتدا است تا دانشجویان بتوانند با برنامه‌ریزی مناسب، پروژه و ارائه خود را به بهترین شکل آماده کنند.

۷. کار گروهی و مسئولیت اعضا

این پروژه به صورت گروهی انجام می شود و انتظار می رود هر دو عضو گروه در انجام آن مشارکت واقعی داشته باشند.

اعضای گروه باید از ابتدا درباره تقسیم وظایف، زمان بندی و نحوه همکاری با یکدیگر به توافق برسند. بهتر است کارها به روزهای پایانی موکول نشود و هر دو عضو در جریان همه بخش های اصلی پروژه باشند.

اگر یکی از اعضای گروه همکاری لازم را انجام نمی دهد، ابتدا تلاش کنید مسئله را از طریق گفت و گو و تقسیم وظایف روشن تر حل کنید. گزارش دادن مشکل به استاد یا دستیاران آموزشی باید **آخرین راه حل** باشد، زمانی که مطمئن هستید مشکل با گفت و گوی مستقیم و تلاش برای همکاری حل نمی شود.

در صورت وجود مشارکت نابرابر، امکان در نظر گرفتن نمره متفاوت برای اعضای گروه وجود دارد.

۸. ارتباط با دستیاران آموزشی

قبل از طرح سؤال درباره پروژه، ابتدا توضیحات این ویکی را کامل مطالعه کنید. بسیاری از پرسش های اصلی درباره ساختار، مراحل و انتظارات پروژه در همین ویکی توضیح داده شده است و ممکن است مطالب جدید نیز به مرور به آن افزوده شود.

در صورتی که پس از مطالعه کامل این توضیحات همچنان سؤال یا ابهامی داشتید، می توانید با دستیاران آموزشی درس تنها از روش ارتباطی زیر در ارتباط باشید:

• پریناز قاسمی – parinaz.ghasemi@ut.ac.ir

• علی رجبزاده – ali.rajabzadeh@ut.ac.ir

• مبین روحی – mobin.roohi@ut.ac.ir

اگر تعداد زیادی از دانشجویان نیاز به توضیح بیشتر داشته باشند، امکان برگزاری یک جلسه توضیح پروژه در بستر **BigBlueButton** وجود دارد.

با آرزوی موفقیت

1	محمد امین شیرمحمدی	610301148
1	امیررضا نعیمی	610300107
2	رضا همایون	610302207
2	امیر حسین کارگرفرد	610302177
3	پارسا ستایش	610303156
3	امیر مهدی اسمعیل وندی	610303105
4	نیما غری	610302171
4	نیکان غدیری ثانی	610302170
5	علیرضا شمسعی	610302217
5	مهدی رفیعی	610302149
6	محمد مهدی اسماعیلیان	610302113
6	ریحانه صابر	610303157
7	بهار مرعشی	610302212
7	ساینا دیبا	610302141
8	هستی جهان تیغ	610302135
8	کیما طاهری	610302165
9	سارا اسماعیلی	610303104
9	سحر مهاجری	610303207
10	امیررضا گنجی	610302216
10	علی گائینی	610302184
11	شاپان گورانی رکنی	610303187
11	بردیا برقی مقدم	610303118
12	مسیح سودمند	610302155
12	محمد جلیل رستم پور	610302144
13	سوگل علی محمدی	610300212
13	عسل یزدان پناه	610002071
14	ماهک اسدالله زاده	610301105
14	حنانه ایوبی	610301111
15	مبین قربانی	610302175
15	فرناز نصرآبادی	610004015
16	ارشک عطار	610302167
16	محمد امین مسلمی	610302099
17	آیدا کارگر	610002027
17	زهرا احمدزاده	610003007
18	آرینا کرمی	610302179
18	مهان شایگانی	610302157
19	پرهام قویدل	610303183
19	بیتا کریمی	610302181
20	فائزه نجفی	610301193
20	علی اشکوری	610002057
21	شاهین اکبرآبادی	610303110
21	کامیار رضائی شهاب	610303149
22	پویا احمدی	610303100
22	امیرحسین لطفی	610303190
23	عرفان کاهانی	610001046
23	مریم صفاهیه	610302161
24	مهسا حکیمی	610300043
24	باران اعتمادی	610301107

25	دیاکو موسی پور	610302200
25	سیدسہیل رئیس الساداتی	610300052
26	محمد حسام معراجی فر	610302198
26	محمد رضا خواجه وند	610303135
27	سجاد بہروزی خواہ	610300027
27	پارمیدا نوروزی	610003038
28	رادمہر میرادی	610302201
28	مریم تقی نسب	610302132
29	مشکات بدخشان	610301113
29	عطیہ خدائی	610301129
30	آیلین گلچین	610302185
30	فاطمہ کبریایی	610302178
31	سپہر قرشی	610302176
31	علیرضا عظیمیان	610302218
32	یگانہ قادری	610302174
32	اروین بہرامی	610301202
33	امیر محمد معبودی	610303202
33	محمد حسین جعفری	610303125
34	ایلیا روش	610302150
34	امیر رضا مزینانی	610301205
35	علی ابوکاظم پور امیری	610302106
35	کیوان تاج فر	610301118
36	امیر مہدی بدری	610300025
36	ترنج عسگری	610302166
37	ہیمن شیخ الاسلامی	610399214
37	سبا اکبری جونوشی	610300020
38	محمد عرفان گوہ	610302186
38	آرش نیکزاد	610301195
39	آرین حسن زادہ	610301126
39	محسن روحی	610003058
40	کوثر احمدی	610302109
40	نازنین درویشی	610302139
41	ملیکا شفیعی	610302160
41	محسن مولائی	610303206
42		
42		
43		
43		
44		
44		